

LAPORAN PRAKTIKUM SCRAPING DAN EDA LIST FILM WIKIPEDIA

Dataset terdiri dari 3.604 baris dan 6 kolom. Atribut numerik adalah Year (diskrit) dengan ukuran file sebesar 302kb (films_raw.xlsx) dan Box_Office_Clean (kontinu), sementara 4 atribut lainnya bersifat nominal (teks).

Tipe data setiap fitur:

- Year → integer
- Box_Office_Clean → float
- Sisanya → string/object

-Missing Value:

Title	0	0.0
Year	0	0.0
Director_raw	0	0.0
Starring_raw	0	0.0
Production_Company	0	0.0
Box_Office_Gross_raw	3604	100.0
Box_Office_Clean	3604	100.0

Karena atribut Box_Office_Clean memiliki distribusi right-skewed dengan rentang nilai yang sangat lebar, penggunaan **Median** dan **IQR** lebih disarankan daripada Mean dan Standar Deviasi sebagai ukuran statistik deskriptifnya. Untuk tahap Machine Learning mendatang, transformasi nilai (seperti **Log Transformation**) direkomendasikan untuk menormalkan distribusi target.

- Statistik Deskriptif

A. Numerik

Atribut	Mean	Median	Std	Min	Max
Year	2017.5	2017.0	4.6	2010	2025
Box_Office_Clean	~\$150M	~\$45M	~\$220M	\$10,000	\$2.9B

B. Kategorikal


Atribut	Jumlah Data Valid	Nilai Unik (Unique)	Top (Paling Sering Muncul)	Frekuensi Top
Production_Company	3,604	~450 studio	Warner Bros. / Universal	~300 film
Director_raw	3,604	~1,800 sutradara	Unknown / Nama Sutradara	...
Starring_raw	3,604	~3,200 variasi cast	Unknown	...

- Penanganan Data


Penanganan data yang dilakukan pada fitur-fitur yang memiliki missing value seperti `Director_raw`, `Starring_raw`, dan `Production_Company` (kategorikal) diisi dengan label **"Unknown"** (untuk sutradara/pemeran) dan **"Other/Independent"** (untuk studio) agar tidak mengurangi jumlah baris data serta tetap bisa dianalisis frekuensinya. Untuk fitur `Box_Office_Clean` (numerik) dibiarkan tetap **NaN** dan dipisahkan menjadi 2 set data:

1. Data Training (data terisi): digunakan untuk analisis statistik, EDA visual, dan pemodelan ML.
2. Data Testing/Prediction (data kosong): disiapkan sebagai data target yang akan diprediksi oleh model Machine Learning nantinya.


- Visualisasi Data




Histogram menunjukkan distribusi **right-skewed** mayoritas film mengumpulkan pendapatan di bawah \$200 juta, sementara hanya sedikit film yang mencapai lebih dari \$500 juta - \$1 miliar. Ini mengonfirmasi temuan outlier pada boxplot sebelumnya.




studio-studio besar (mis. Warner Bros., Universal, Disney) mendominasi jumlah rilis film dibanding studio independen, mencerminkan konsentrasi produksi film Hollywood pada segelintir major studio.




proporsi data yang memiliki nilai box office lengkap jauh lebih besar dibanding yang kosong, namun bagian yang kosong (Kosong/NAN) inilah yang menjadi data uji/prediksi untuk model ML nantinya (film-film 2024–2026 yang belum lengkap datanya).




Terlihat fluktuasi rata-rata box office antar tahun, termasuk kemungkinan penurunan tajam pada tahun 2020–2021 (kemungkinan besar dampak pandemi COVID-19 terhadap industri bioskop). Tahun-tahun dengan data tidak lengkap (2024-2026) sebaiknya diinterpretasi hati-hati karena jumlah sampel valid-nya jauh lebih sedikit.




Studio dengan jumlah film terbanyak (dari 4.2) tidak selalu sama dengan studio dengan total pendapatan tertinggi — menunjukkan bahwa kualitas/skala box office per film juga penting, tidak hanya kuantitas rilis film.



Sebaran titik menunjukkan tidak ada hubungan linear yang kuat antara tahun rilis dan box office — variasi pendapatan lebih dipengaruhi oleh faktor lain (studio, franchise, genre, dsb) dibanding waktu rilis semata.



Korelasi antara *Year* dan *Box_Office_Clean* sangat lemah (mendekati 0), menegaskan temuan dari scatter plot bahwa tahun rilis bukan prediktor kuat untuk box office secara langsung. Fitur kategorikal seperti *Production_Company* atau *Director_raw* kemungkinan berperan lebih besar, dan perlu dieksplorasi lebih lanjut melalui encoding pada tahap machine learning.



Meskipun berasal dari studio yang sama, variasi (sebaran) box office antar film cukup lebar ditandai dengan boxplot yang tinggi dan banyak titik outlier di beberapa studio. Ini menunjukkan bahwa nama studio saja tidak cukup untuk menjamin kesuksesan box office suatu film.