

LAPORAN PRAKTIKUM SCRAPING DAN EDA LIST FILM WIKIPEDIA

Dataset yang berasal dari List of American films of 2010-2025 ini terdiri dari 3.604 baris dan 6 kolom. Tujuan dari pengambilan dataset ini untuk memprediksi pendapatan company dalam pembuatan film. Atribut-atribut yang ada pada dataset ini adalah numerik Year (diskrit) dengan ukuran file sebesar 302kb (films_raw.xlsx) dan Box_Office_Clean (kontinu), sementara 4 atribut lainnya bersifat nominal (teks).

Tipe data setiap fitur:

- Year → integer
- Box_Office_Clean → float
- Sisanya → string/object

-Missing Value:

Title	0	0.0
Year	0	0.0
Director_raw	0	0.0
Starring_raw	0	0.0
Production_Company	0	0.0
Box_Office_Gross_raw	3577	99.25
Box_Office_Clean	3577	99,25

Karena atribut Box_Office_Clean memiliki distribusi right-skewed dengan rentang nilai yang sangat lebar, penggunaan **Median** dan **IQR** lebih disarankan daripada Mean dan Standar Deviasi sebagai ukuran statistik deskriptifnya. Untuk tahap Machine Learning mendatang, transformasi nilai (seperti **Log Transformation**) direkomendasikan untuk menormalkan distribusi target.

- Statistik Deskriptif

A. Numerik

Atribut	Mean	Median	Std	Min	Max
Year	2017.5	2017.0	4.6	2010	2025
Box_Office_Clean	3.811597e+08	369695210.0	1.515330e+08	46801036.0	678815482.0

B. Kategorikal


Atribut	Jumlah Data Valid	Nilai Unik (Unique)	Top (Paling Sering Muncul)	Frekuensi Top
Production_Company	3,604	~450 studio	Warner Bros. / Universal	~300 film
Director_raw	3,604	~1,800 sutradara	Unknown / Nama Sutradara	...
Starring_raw	3,604	~3,200 variasi cast	Unknown	...

- Penanganan Data


Penanganan data yang dilakukan pada fitur-fitur yang memiliki missing value seperti **Director_raw**, **Starring_raw**, dan **Production_Company**(kategorikal) diisi dengan label "**Unknown**" (untuk sutradara/pemeran) dan "**Other/Independent**" (untuk studio) agar tidak mengurangi jumlah baris data serta tetap bisa dianalisis frekuensinya. Untuk fitur **Box_Office_Clean** (numerik) dibiarkan tetap **NaN** dan dipisahkan menjadi 2 set data:

1. Data Training (data terisi): digunakan untuk analisis statistik, EDA visual, dan pemodelan ML.
2. Data Testing/Prediction (data kosong): disiapkan sebagai data target yang akan diprediksi oleh model Machine Learning nantinya.


- Visualisasi Data




Insight: Histogram terlihat bahwa beberapa studio tidak memberikan data pendapatannya dan pendapatan didominasi oleh studio besar



studio-studio besar (mis. Warner Bros., Universal, Disney) mendominasi jumlah rilis film dibanding studio independen, mencerminkan konsentrasi produksi film Hollywood pada segelintir major studio.



proporsi data yang memiliki nilai box office lengkap jauh lebih besar dibanding yang kosong, namun bagian yang kosong (Kosong/NAN) inilah yang menjadi data uji/prediksi untuk model ML nantinya (film-film 2024–2026 yang belum lengkap datanya).




****Insight:**** terlihat fluktuasi rata-rata box office antar tahun, termasuk kemungkinan penurunan


tajam pada tahun 2020–2021 (kemungkinan besar dampak pandemi COVID-19 terhadap industri bioskop).

Tahun-tahun dengan data tidak lengkap (2024–2026) sebaiknya diinterpretasi hati-hati karena jumlah


sampel valid-nya jauh lebih sedikit.



Insight: Histogram terlihat bahwa studio menguasai chart karena dari data yang tersedia studio studio lain tidak tersedia




Insight: Histogram terlihat pada tahun 2018 mengalami peningkatan yang tinggi dan terjadi penurunan drastis di tahun 2020. Kemudian data terlihat kembali normal di tahun 2022 tepat setelah selesai pandemi.



Korelasi antara *Year* dan *Box_Office_Clean* sangat lemah (mendekati 0), menegaskan temuan dari scatter plot bahwa tahun rilis bukan prediktor kuat untuk box office secara langsung.

Fitur kategorikal seperti *Production_Company* atau *Director_raw* kemungkinan berperan lebih besar, dan perlu dieksplorasi lebih lanjut melalui encoding pada tahap machine learning.



Deteksi outlier pada atribut *Box_Office_Clean* dilakukan menggunakan metode IQR (Interquartile Range) dengan batas bawah = $Q1 - 1.5 \times IQR$ dan batas atas = $Q3 + 1.5 \times IQR$. Dari 27 data valid, **tidak ditemukan outlier** (0 dari 27 data berada di luar batas IQR). Hasil ini perlu diinterpretasi hati-hati mengingat ukuran sampel yang sangat kecil (27 dari 3.604 total baris, atau hanya 0,75%) ketiadaan outlier lebih mungkin disebabkan oleh terbatasnya data yang tersedia untuk dianalisis, bukan indikasi bahwa data box office film benar-benar seragam.